

HMIN318M

Imagerie (médicale) 3D

Segmentation (1/2)

Noura Faraj


noura.faraj@umontpellier.fr

Source Gérard Subsol


Un voxel parmi ses voisins

- Voisinage(**neighborhood**) défini par la connexité (**connectivity**)

Dans une image :



4-voisinage




8-voisinage


Un voxel parmi ses voisins

- Voisinage(**neighborhood**) défini par la connexité (**connectivity**)


Dans une grille de voxels :



6-connectivity



18-connectivity




26-connectivity


Un voxel parmi ses voisins

- Voisinage(**neighborhood**) défini par la connexité (**connectivity**)


Dans une grille de voxels :



Seulement les faces
 $1+4+1 = 6$ voisins



18-connectivity




26-connectivity


Un voxel parmi ses voisins

- Voisinage(**neighborhood**) défini par la connexité (**connectivity**)


Dans une grille de voxels ·



6-connectivity



Arêtes ou faces
 $5+8+5 = 18$ voisins




26-connectivity


Un voxel parmi ses voisins

- Voisinage(**neighborhood**) défini par la connexité (**connectivity**)


Dans une grille de voxels :



6-connectivity




18-connectivity



Arêtes, faces ou coins
 $9+8+9 = 26$ voisins

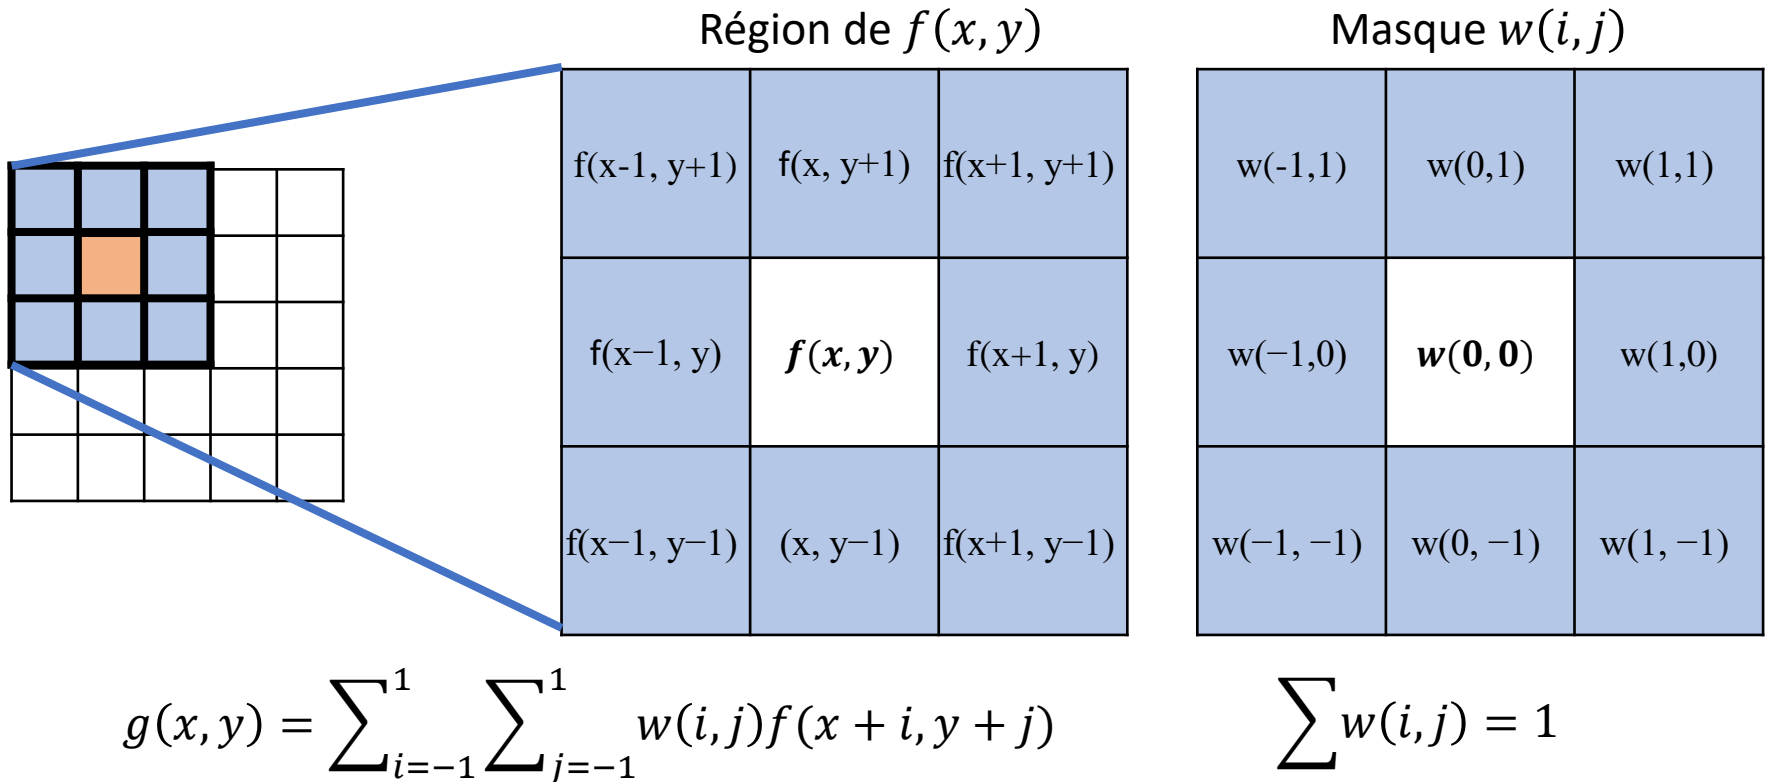
Un voxel parmi ses voisins

- Voisinage(**neighborhood**) défini par la connexité (**connectivity**)
- Notion de taille (**size**) de voisinage: voisin du voisin du voisin....



Filtrage linéaire

- Filtres de traitement d'images (2D ou) 3D souvent linéaires.
→ définis par une convolution avec une fonction de pondération (**masque**/**mask** ou **noyau**/**kernel**) définie sur un voisinage 3D.




Exemples de filtre linéaire

Moyenne locale
pour lisser
(smoothing) ou
flouter (blurring)

$$M(x, y, z) = 1/27$$

1	1	1
1	1	1
1	1	1




Exemples de filtre linéaire

La taille du masque peut être plus ou moins grande.

$$M(x, y, z) = 1/147$$

1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1
1	1	1	1	1	1	1




Exemples de filtre linéaire

Différences pour
rehausser le
contraste (**contrast
enhancement**)



$$M(x, y, z) = 1/27$$

0	-1	0
-1	5	-1
0	-1	0



Filtre linéaire

Lissage gaussien



Exemple : $\sigma = 1,4$

$$h = \frac{1}{159} \begin{bmatrix} 2 & 4 & 5 & 4 & 2 \\ 4 & 9 & 12 & 9 & 4 \\ 5 & 12 & 15 & 12 & 5 \\ 4 & 9 & 12 & 9 & 4 \\ 2 & 4 & 5 & 4 & 2 \end{bmatrix}$$

Autres filtres

Filtres non linéaires : eg. Filtre médian(**median filter**), efficace contre le bruit « poivre et sel » ou bruit impulsif.



Autres filtres

Filtres non linéaires : eg. Filtre médian(**median filter**), efficace contre le bruit « poivre et sel » ou bruit impulsionnel.

On considère 9 pixels avec une valeur aberrante (111) :

5	6	7
6	111	8
7	8	9

voisinage par valeurs croissantes :

5	6	6	7	7	8	8	9	111
---	---	---	---	---	---	---	---	-----

Prendre la valeur médiane (ici 7)



5	6	7
6	7	8
7	8	9

https://fr.wikipedia.org/wiki/Filtre_m%C3%A9dian

Notion de gradient 3D

Gradient 3D = vecteur des dérivées du signal de l'image (=intensité) selon les 3 directions x y z.

$$\nabla f = \text{grad } f = \left\langle \frac{\partial f}{\partial x}(x, y, z), \frac{\partial f}{\partial y}(x, y, z), \frac{\partial f}{\partial z}(x, y, z) \right\rangle$$

- Vecteur gradient dirigé dans la direction de la plus forte variation locale de l'intensité.
- Pointe vers les zones de plus forte intensité.
- Sa norme donne une indication sur l'importance de la variation.
→ contours : valeurs élevées de la norme du gradient.

Détection de contours

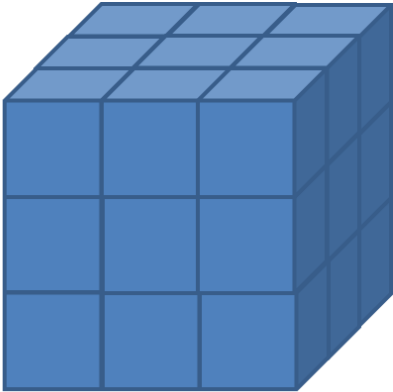
Coordonnées du gradient 3D calculée à l'aide de filtres linéaires par différences finies.

Exemple: filtres de **Sobel** en 3D

Masque pour la direction z

$$G_z = \begin{array}{|c|c|c|} \hline -1 & -2 & -1 \\ \hline -2 & -4 & -2 \\ \hline -1 & -2 & -1 \\ \hline \end{array} \quad \begin{array}{|c|c|c|} \hline 0 & 0 & 0 \\ \hline 0 & 0 & 0 \\ \hline 0 & 0 & 0 \\ \hline \end{array} \quad \begin{array}{|c|c|c|} \hline +1 & +2 & +1 \\ \hline +2 & +4 & +2 \\ \hline +1 & +2 & +1 \\ \hline \end{array} \quad *$$

$(x, y, z - 1) \qquad (x, y, z) \qquad (x, y, z + 1)$



Amplitude du gradient

$$G = \sqrt{G_x^2 + G_y^2 + G_z^2}$$

Opérateur de convolution


Détection de contours : prendre les « grandes » valeurs du gradient

Trouver un seuil qui ne doit pas être trop sensible au bruit...

Problème de la segmentation

Visualisation volumique

- **Problème** : comment voir à l'intérieur de l'image ?
- **Principe** :
 - couleur et opacité pour chaque voxel en fonction de son intensité ;
 - sélectionner un point de vue
 - «intégrer» couleur et opacité (*ray casting*).

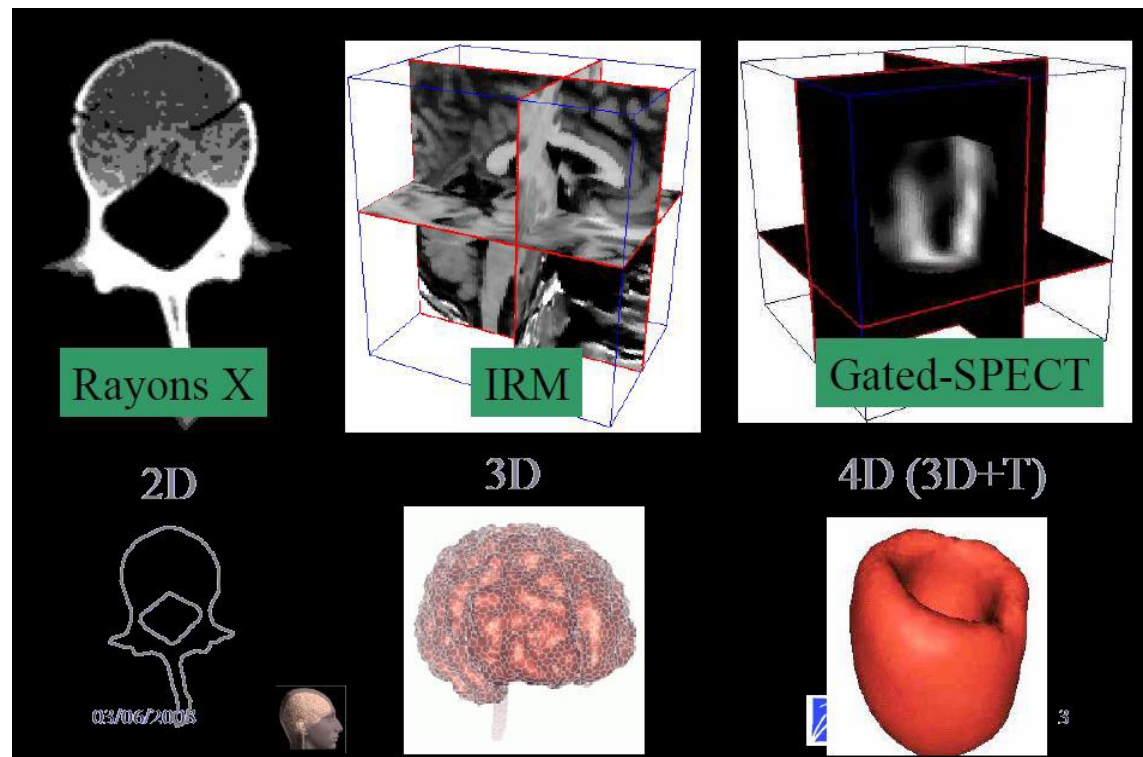


→ Mais il ne s'agit que d'une «coloration» des voxels qui permet d'obtenir une image utile mais pas exactement précise.

Le problème de la segmentation (1)

- Pour les applications biomédicales, on a besoin de :
 - Définir une RDI ou **ROI** (Region Of Interest)
 - Définir la surface d'une structure anatomique pour la visualiser sous forme d'un maillage 3D (rendu surfacique)
 - Obtenir des paramètres quantitatifs (ex. volume d'une lésion)
 - ...

Décomposer l'image
en sous-parties =
Segmentation




Le problème de la segmentation (2)

- Pour une image I : $I = \bigcup_{k=1}^K S_k$ S_k éléments disjoints de I
- **Segmentation** : Subdivision de l'image ou du volume en différentes entités "significatives" (objets, régions, frontières).
- **Classification** : classer chaque pixel/voxel dans un ensemble donné de catégories.
- **Labélisation** : Assigner un label à une région segmentée ou un groupe de pixels/ voxels classifié.

Le problème de la segmentation (3)

- Détermination des **voxels** appartenant à la ROI.
 - Distribution de probabilités d'appartenance à chaque voxel
- Définition de la surface **frontière**



Image



Segmentation Région




Segmentation
Frontière

Le problème de la segmentation (4)


- De **nombreux algorithmes** qui dépendent :
 - du type d'image et de ses artefacts,
 - de la structure à segmenter
 - et de l'application (précision).
- Difficile à valider
 - «fantômes» sont difficiles à fabriquer,
 - images de synthèse non réalistes
 - et les segmentations 3D d'experts peuvent être très variables...

Le problème de la segmentation (4)

- Segmentations d'experts



5 segmentations de la même structure par le **même** expert (variabilité **intra-individuelle**)



Segmentation par **3 experts différents** (variabilité **inter-individuelle**)

Quelques méthodes de
segmentation 3D «région »

Seuillage d'intensité (1)

La structure que l'on cherche à segmenter est caractérisée par son intensité dans l'image 3D → seuillage de l'image


Exemples :

- [MANIX](#)
 - Tête : ~500-700
 - Os : ~1200
- [Engine](#)
 - Structure 1 : pic autour de 140
 - Structure 2 : > 170

Mais... comment trouver un seuil significatif et reproductible à partir de l'histogramme ?

Mais comment fixer le(s) seuil(s) ? (1)

Un exemple de méthode très simple : algorithme de Zack (1977)



*Zack GW, Rogers WE, LattSA (1977),
"Automatic measurement of sister chromatid
exchange frequency", J. Histochem. Cytochem.
25 (7): 741–53,*

Fonctionne en particulier bien pour séparer le fond (~pic) /
structure (~bruit faible étalé)


Mais comment fixer le(s) seuil(s) ? (2)

Un autre exemple de méthode très simple : algorithme d'Otsu (1977) :

- Recherche exhaustive du seuil minimisant la variance intra-classe, définie comme une somme pondérée de la variance des 2 classes :

$$\sigma_w^2 = \omega_1(t)\sigma_1^2(t) + \omega_2(t)\sigma_2^2(t)$$

- Exemple




A 6-level greyscale image and its histogram

Nobuyuki Otsu (1979). "A threshold selection method from gray-level histograms". *IEEE Trans. Sys., Man., Cyber.* **9**(1): 62–66.

Mais comment fixer le(s) seuil(s) ? (2)


Pour un t ($t=3$)

Background



$$\text{Weight } W_b = \frac{8 + 7 + 2}{36} = 0.4722$$

Foreground



$$\text{Weight } W_f = \frac{6 + 9 + 4}{36} = 0.5278$$

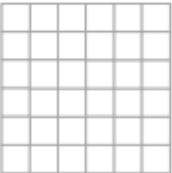
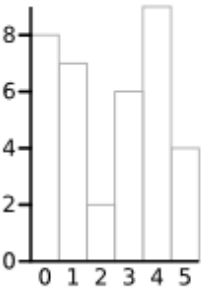

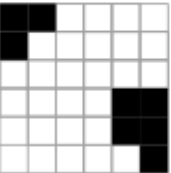
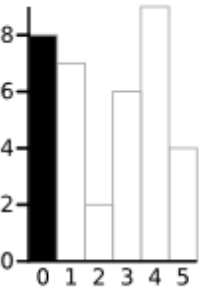

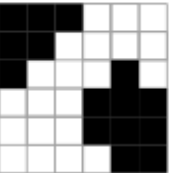
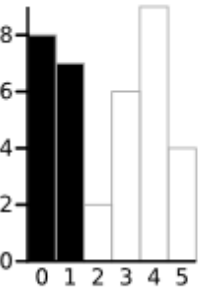

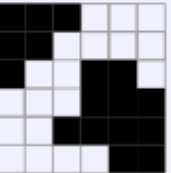
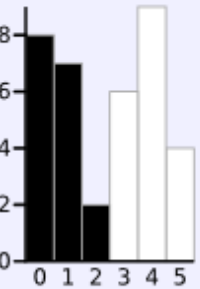

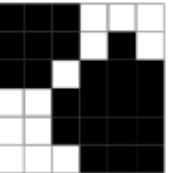
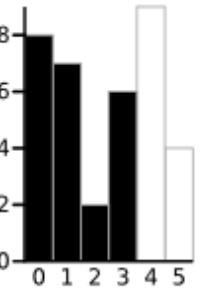

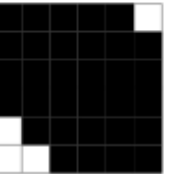
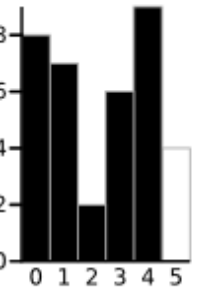

$$\text{Mean } \mu_f = \frac{(3 \times 6) + (4 \times 9) + (5 \times 4)}{19} = 3.8947$$

$$\begin{aligned} \text{Variance } \sigma_f^2 &= \frac{((3 - 3.8947)^2 \times 6) + ((4 - 3.8947)^2 \times 9) + ((5 - 3.8947)^2 \times 4)}{19} \\ &= \frac{(4.8033 \times 6) + (0.0997 \times 9) + (4.8864 \times 4)}{19} \\ &= 0.5152 \end{aligned}$$

Calculer la variance intra-classe :

$$\begin{aligned} \sigma_w^2 &= \omega_b(t)\sigma_b^2(t) + \omega_f(t)\sigma_f^2(t) = 0.4722 \times 0.4637 + 0.5278 \times 0.5152 \\ &= 0.4909 \end{aligned}$$

Mais comment fixer le(s) seuil(s) ? (2)

Threshold	T=0	T=1	T=2	T=3	T=4	T=5
	  	  	  	  	  	  
Weight, Background	$W_b = 0$	$W_b = 0.222$	$W_b = 0.4167$	$W_b = 0.4722$	$W_b = 0.6389$	$W_b = 0.8889$
Mean, Background	$M_b = 0$	$M_b = 0$	$M_b = 0.4667$	$M_b = 0.6471$	$M_b = 1.2609$	$M_b = 2.0313$
Variance, Background	$\sigma_b^2 = 0$	$\sigma_b^2 = 0$	$\sigma_b^2 = 0.2489$	$\sigma_b^2 = 0.4637$	$\sigma_b^2 = 1.4102$	$\sigma_b^2 = 2.5303$
Weight, Foreground	$W_f = 1$	$W_f = 0.7778$	$W_f = 0.5833$	$W_f = 0.5278$	$W_f = 0.3611$	$W_f = 0.1111$
Mean, Foreground	$M_f = 2.3611$	$M_f = 3.0357$	$M_f = 3.7143$	$M_f = 3.8947$	$M_f = 4.3077$	$M_f = 5.000$
Variance, Foreground	$\sigma_f^2 = 3.1196$	$\sigma_f^2 = 1.9639$	$\sigma_f^2 = 0.7755$	$\sigma_f^2 = 0.5152$	$\sigma_f^2 = 0.2130$	$\sigma_f^2 = 0$
Within Class Variance	$\sigma_W^2 = 3.1196$	$\sigma_W^2 = 1.5268$	$\sigma_W^2 = 0.5561$	$\sigma_W^2 = 0.4909$	$\sigma_W^2 = 0.9779$	$\sigma_W^2 = 2.2491$

Mais comment fixer le(s) seuil(s) ? (2)

Un autre exemple de méthode très simple : algorithme d'Otsu (1977) :

$$\sigma_w^2 = \omega_1(t)\sigma_1^2(t) + \omega_2(t)\sigma_2^2(t)$$

- [Engine](#)
 - Otsu = 70

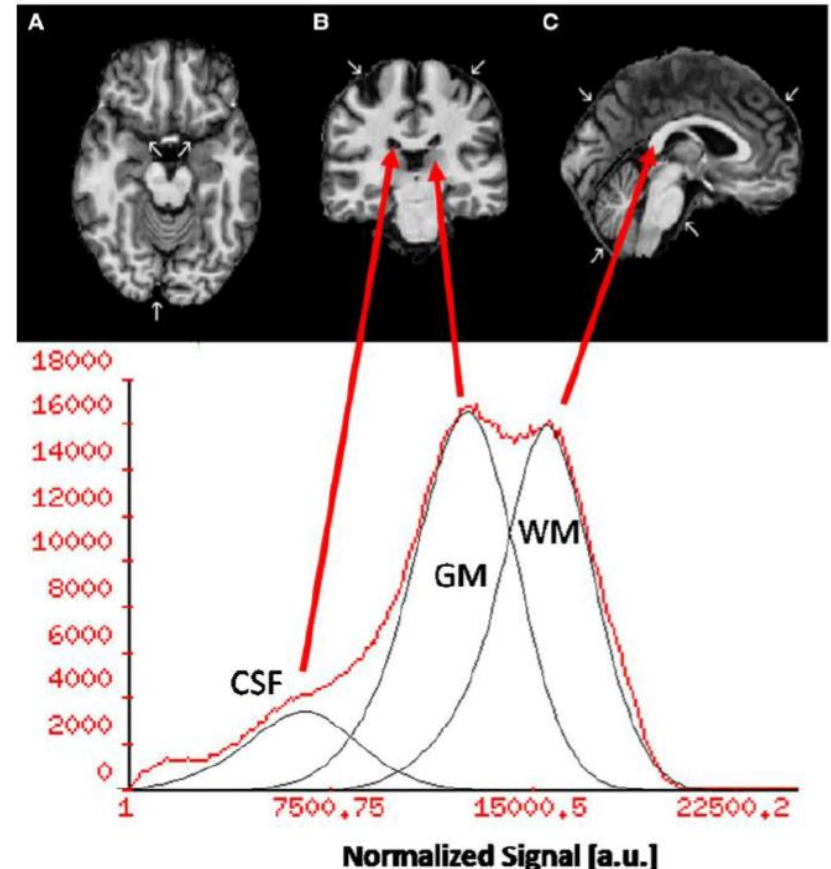
*Nobuyuki Otsu (1979). "A threshold selection method from gray-level histograms".
IEEE Trans. Sys., Man., Cyber. 9(1): 62–66.*

Mais comment fixer le(s) seuil(s) ? (3)

Seuillage est **trop strict** car intensités non uniformes dans structure anatomique :

- «texture» du tissu,
- artefact de volume partiel
- ou de la présence de produit de contraste.

Helms, G. Segmentation of human brain using structural MRI. Magn Reson Mater Phy (2016) 29: 111




→ Modéliser la **distribution des intensités** au sein de chaque structure par des fonctions plus «adoucies» comme des Gaussiennes.

Mais comment fixer le(s) seuil(s) ? (3)

Soit l'histogramme $H = \{h_j\}$

Où h_j = nombre de voxels / $I(\text{voxel}) = j$




On suppose qu'il y a K structures différentes S_k caractérisées chacune par une distribution des intensités suivant une loi Gaussienne G de paramètres $\{\mu_k, \sigma_k\}$.

On peut alors modéliser l'histogramme H par une somme de k Gaussiennes définies par les paramètres : $\{a_k, \mu_k, \sigma_k\}_{k=1 \text{ à } K}$ où a_k est la pondération (de somme 1).

On cherche alors à ajuster l'histogramme H et le modèle.

Pour les voxels d'intensité $j \rightarrow \sum_{k=1}^K a_k \cdot G[\mu_k, \sigma_k](j) \approx h_j$

Mais comment fixer le(s) seuil(s) ? (3)



Pour les voxels d'intensité $j \rightarrow \sum_{k=1}^K a_k \cdot G[\mu_k, \sigma_k](j) \approx h_j$

- Pas de solution analytique pour trouver les paramètres optimaux.
- On utilise la technique itérative EM (Expectation/Minimization) en 2 étapes :
- On suppose qu'on a une initialisation $\{a_k, \mu_k, \sigma_k\}_{k=1 \text{ à } K}$


E : Calcul de la probabilité $p_{j \in i} = (\text{voxel d'intensité } j) \in S_i$, d'après le modèle théorique:

$$p_{j \in i} = a_i \cdot G[\mu_i, \sigma_i](j) / \sum_{k=1}^K a_k \cdot G[\mu_k, \sigma_k](j)$$

numérateur = valeur s'il n'y avait que la structure i

dénominateur = valeur en tenant compte de toutes les structures

Mais comment fixer le(s) seuil(s) ? (3)




Pour les voxels d'intensité $j \rightarrow \sum_{k=1}^K a_k \cdot G[\mu_k, \sigma_k](j) \approx h_j$

- **M** : Une fois qu'on a les probabilités «théoriques» $p_{j \in i} = (\text{voxel d'intensité } j) \in S_i$, on peut actualiser les paramètres (a_k, μ_k, σ_k) du modèle par les estimateurs classiques sur les données expérimentales :

$$a'_i = \sum_j p_{j \in i} \cdot h_j \quad \mu'_i = \sum_j (p_{j \in i} \cdot h_j) \cdot j \quad \sigma'_i = \sqrt{\sum_j ((p_{j \in i} \cdot h_j) \cdot j - \mu'_i)^2}$$

→ On itère jusqu'à stabilité.

Mais comment fixer le(s) seuil(s) ? (3)




Pour les voxels d'intensité $j \rightarrow \sum_{k=1}^K \rightarrow \sum_{k=1}^K a_k \cdot G[\mu_k, \sigma_k](j) \approx h_j$

→ A la fin, on affectera l'intensité j à la structure i qui maximise
 $p_{ij} = (\text{voxel d'intensité } j) \in (\text{structure } i)$


On peut montrer que le processus converge vers un optimum local mais... il est **sensible à l'initialisation** et... il faut connaître le **nombre de structures**...

Prendre en compte les relations spatiales ? (1)


- On va utiliser la notion de voisinage ou de connexité.



6-connectivity



18-connectivity




26-connectivity

- Algorithme de «Region Growing» (croissance de région)
 - On part d'un voxel graine
 - On agrège un voxel voisin si son intensité est «proche».
- Version interactive (clic = graine, roulette = réglage de la tolérance).
- On peut aussi utiliser des statistiques sur la zone déjà segmentée pour décider de l'inclusion d'un nouveau voxel.

MAIS

- Sensible au bruit et à la variabilité de l'image.
- Grande complexité de calcul.

Prendre en compte les relations spatiales ? (2)



Après une étape de segmentation, plusieurs structures reliées par des petits ponts ou alors plusieurs morceaux d'une même structure séparés par des petits vides.

→ Utilisation d'opérateurs de morphologie mathématique (érosion, recherche de composantes connexes, dilatation) → **TP1 Segmentation automatique du cerveau dans des images IRM en pondération T1.**






Image originale (en noir : l'objet ; en blanc : le fond)




Dilatation par un carré 3x3 : les pixels noirs et gris font partie de l'ensemble résultant




Érosion par un carré 3x3 : seuls les pixels noirs font partie de l'ensemble résultant

Images multimodales ?

- Par exemple, une IRM de la tête en pondération [T1](#) et [T2](#).




- Voxel de position (x,y,z) \rightarrow 2 intensités I dans a et J dans b : image de histogramme conjoint.




Images multimodales ?

- Par exemple, une IRM de la tête en pondération [T1](#) et [T2](#).



- On peut essayer d'effectuer une classification non-supervisée des pixels de l'histogramme conjoint par l'algorithme «classique» des k-means :
 - On a k classes, chaque classe C_i va être définie par un point 2D (I_i, J_i)
 - Chaque voxel $(x, y, z) \rightarrow (I, J)$ est affecté à la classe C_i telle que $d((I, J), (I_i, J_i))$ minimale
 - Pour chaque classe C_i , on calcule le barycentre des (I, J) des voxels affectés $\rightarrow (I_i, J_i)$
 - On itère jusqu'à convergence... (dans un minimum local pour le critère k-means)
- Donne une segmentation limitée...

Limites des méthodes région ?



- Les artefacts d'acquisition (inhomogénéité du champ en IRM, volume partiel en CT et IRM...) font varier l'intensité des structures dans l'image.
→ Une notion plus stable peut être celle de la discontinuité d'intensité (= frontière, **contour**...)